

**Turno 1
(Cold Prefill):**

storico_messaggi[0]
System Prompt + REGOLE-RETE.md (~5900 tk)
[Calcolo Tensori KV in VRAM: ~695 tk/s]

Prompt 1
(Nuovo Input)

**TTFT:
20.10 s**

Riutilizzo Tensori in VRAM (0 Ricalcoli)

**Turno 2..N
(Cache Hit):**

storico_messaggi[0] INVARIANTE
[PREFISSO GIÀ IN KV CACHE]
[Lettura Istantanea: PPS > 7200 tk/s]

Turno 1..N-1
(Cached)

Nuovo
Input

**TTFT:
0.84 s**