

**Emissione 1° Token
(Istante TTFT)**



TTFT = load_duration + prompt_eval_duration



total_duration (Latenza complessiva End-to-End della chiamata HTTP)